

双周工作汇报

汇报人：巫文杰 指导教师：曹建宇

计算机与信息安全学院

2025 年 10 月 12 日

- **论文：** A Multimodal Large Language Model Framework for Intelligent Perception and Decision-Making in Smart Manufacturing
- **作者：** Wang, Zhang, Jiang, Li
- **期刊：** Sensors (2025), 25, 3072
- **DOI：** 10.3390/s25103072



① 研究动机与问题定义

② 相关工作


③ 方法

④ 实验与结果

⑤ 总结与展望



研究背景与动机



The automated assembly process of the constant velocity joint is shown in <image>, and the production records are provided in <csv file>. Could you help analyze the production cycle time and quality control situation, and also extract the key parameters?

The situation on-site shows that the production cycle time is normal, but there are quality issues with the parts. In particular, Dimension 1 has sudden variations, while Dimension 2 still follows a Gaussian distribution. This suggests that the problem may be concentrated in the process or equipment affecting Dimension 1. Could you please check the relevant processes?

According to the investigation, Dimension 1 represents the pitch circle diameter of the star-shaped raceway. Could you please analyze this based on the statistical data and provide some optimization suggestions?

Since Dimension 1 (the pitch circle diameter) shows a sudden variation while Dimension 2 still follows a Gaussian distribution, it indicates that the issue with Dimension 1 is likely caused by a sudden anomaly in a single process or piece of equipment, rather than a systemic problem. I suggest comparing the raw material batches of the defective parts to check for any batch differences, and also inspecting the wear conditions of molds and fixtures.

- 智能制造含多源异构数据（图像、传感器、生产记录），存在数据孤岛与跨模态融合难题。
- 目标：用多模态大模型实现统一感知与实时决策，打通视觉—信号—文本链路。

讲述提示：先用场景（人机协同的具体例子）吸引听众，再提出三个关键问题（异构、对齐、实时）。



问题定义（精确化）

- 输入模态：图像（高维静态）、传感器信号（时间序列）、文本/生产记录（语义/结构化）。
- 研究要点：
 - ① 将不同模态映射到统一语义 token 空间；
 - ② 设计稳定的跨模态预训练目标（MLM/MVM/MTM）；
 - ③ 构建能同时做 I2T 与 T2I 的双向生成体系，并满足工业级实时性。



① 研究动机与问题定义

② 相关工作

③ 方法

④ 实验与结果

⑤ 总结与展望



相关工作概览

- 通用多模态 LLM: LLaVA、BLIP-2、X2-VLM 等——强在通用域，但工业数据稀缺；
- 工业方向：已有若干振动信号与异常检测尝试，但缺统一框架；
- 差距：少有端到端的工业多模态大模型，尤其缺语义字典 + 双向生成结合。



① 研究动机与问题定义

② 相关工作

③ 方法

④ 实验与结果

⑤ 总结与展望



总体设计思想（一句话）

- 把图像/信号/文本都量化为语义 token，在 Transformer 主干上做联合建模与双向生成。
- 关键组件：视觉编码器（CNN）、信号编码器、动态语义词典、Transformer backbone、双向生成器（I2T/T2I）。




[illegible]

- 说明：使用 CSPDarknet backbone 提取 grid-based 特征，随后 3×3 conv + 4×4 max-pool。
- 讲解要点：视觉特征被设计为 “dense grid vectors”，为后续语义量化做准备。




动态语义词典 (论文 Figure 3)



- 作用：将视觉/信号特征映射到离散语义 embedding (词典索引)，形成与文本 token 类似的表示。
- 关键技术：最近邻匹配 + momentum 更新 (公式见论文)，并用 stop-gradient 处理非可微问题。




模态对齐与输入 (论文 Figure 4)



- 说明：视觉 token、信号 token、文本 token 在位置编码后并入 Transformer；并行化处理与位置信息保留。
- 训练目标：MLM / MVM / MTM 三类任务联合优化。



统一双向生成模块 (论文 Figure 5)



- 支持 I2T (imagetext) 与 T2I (textimage), 共享 Transformer 主干, 仅在输出层微分任务头。
- 训练技巧: token-level teacher-forcing + sequence-level SCST/CLIP rewards, T2I 用 mask-predict 非自回归解码以提速。



① 研究动机与问题定义

② 相关工作

③ 方法

④ 实验与结果

⑤ 总结与展望



实验设置（简要）

- 预训练数据：MS COCO, Visual Genome；微调/评测：Flickr30K, VQA2.0 等。
- 硬件：8×V100；实现：PyTorch。
- 指标：图文检索（R@k）、VQA（acc）、生成（FID, Div-n, CIDEr-D）。



主要结果（图文检索 / VQA / 生成）

Image-Text Retrieval

MS CocoDataset

Algorithm	TR (1k Test Set)	IR (1k Test Set)	TR (5k Test Set)	IR (5k Test Set)
VSE++	87.3	81.4	68.6	57.1
SCAN	90.1	84.1	70.9	59.7
Unicoder-VL	92.4	86.4	72.3	61.0
BLIP-2	92.7	85.2	71.8	60.4
χ^2 -VLM	91.3	85.0	70.7	59.9
UNITER	93.1	87.2	73.5	62.1
Ours	95.0	89.1	75.3	3.7

Flickr30K

Algorithm	TR (R@1)	TR (R@5)	TR (R@10)	IR (R@1)	IR (R@5)	IR (R@10)
VSE++	57.0	64.1	64.9	47.1	59.8	63.2
SCAN	70.0	77.8	78.6	57.2	73.8	76.4
Unicoder-VL	86.1	97.4	98.9	71.8	92.5	95.4
BLIP-2	85.2	89.6	95.7	68.5	89.2	92.4
χ^2 -VLM	84.7	90.1	93.2	67.1	88.1	90.5
UNITER	85.4	96.2	97.1	70.5	88.9	93.8
Ours	87.1	97.2	99.2	71.9	92.3	96.2

Visual Question Answering

Algorithm	Test-Dev	Test-Std	FLOPs (GFLOPs)	Time to First Token (ms)
VILBERT	63.05	63.62	60	415.4
VisualBERT	64.37	65.14	44	354.1
LXMERT	69.02	69.45	90	371.0
BEIT	68.10	68.87	155	584.2
UNITER	71.13	71.78	62	265.7
Ours	73.05	73.32	38	204.3

Results of Multimodal Alignment Tasks

Model	Image Embedding	Pretraining Objectives	FUNSD F1	CORD F1	RVL-CDIP Acc	PubLayNet mAP
1	None	MLM	79.39	85.44	75.73	N/A
2	Linear	MLM	84.07	90.52	94.46	N/A
3	Linear	MLM+MVM	86.75	94.90	93.09	92.38
4	Linear	MLM+MVM+MTM	88.71	95.57	95.38	93.77

Results of Bidirectional Image-Text Generation Model

Method	Div-1 Diversity Metrics (%)	Div-2 Diversity Metrics (%)	CIDeR-D Acc (%)
Base model	20.1	26.2	90.4
Ours	40.6	47.2	78.4

- 图文检索：在 COCO / Flickr30k 上达到或优于多数基线 (R@1/R@5 提升)。
- VQA：比 LXMERT 高 5.8% (test-dev)。
- 生成：FID 显著下降，多样性 (Div-1/2) 提高，但 CIDeR-D 有小幅 trade-off。



消融与稳定性分析

- 没有 MVM（仅将线性图像 embedding 串联）会导致训练不稳定（loss 不收敛）——论文中的 Model2 实验。
- 加入 MVM 与 MTM 可显著改善跨模态对齐与最终任务表现（见表格/曲线）。
- 讲解提示：把消融结果与最初提出的问题（模态不对齐）对应起来讲。



① 研究动机与问题定义

② 相关工作

③ 方法

④ 实验与结果

⑤ 总结与展望



结论要点

- 提出端到端工业场景多模态 LLM 框架：语义词典 + Transformer 主干 + 双向生成。
- 在检索、VQA、生成等任务上展现出强泛化能力与实用价值。
- 技术要点：语义词典稳定模态对齐；MVM/MTM 预训练任务确保视觉信息被充分学习。



未来工作（建议）

- 构建/发布大规模工业多模态数据集以提升泛化；
- 优化实时推理与流式输入支持；
- 增强模型可解释性（对决策链路的可视化与审计）；
- 研究增量在线学习与小样本微调在工业部署中的实用化路径。



WELCOME FEEDBACK!

