


双周工作汇报

汇报人：巫文杰 指导教师：曹建宇

计算机与信息安全学院

2025 年 11 月 6 日



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述
- ④ 讨论与启发
- ⑤ Q&A



研究背景与问题动机

- **Active Queue Management (AQM)**: 网络路由器通过主动丢包或 ECN 标记避免拥塞。
- 传统方法（如 CoDel、PIE、L4S）依赖固定规则，难以应对：
 - 异构流量类型（TCP、UDP、DCTCP 等）
 - 高速 / 低延迟场景（5G、卫星网）
- 作者提出：**能否让 LLM 参与队列控制决策？**

挑战：

- ① 网络状态是多模态时序数据，不是自然语言；
- ② LLM 推理延迟高，不适合实时决策；
- ③ 完整微调代价巨大。



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述
- ④ 讨论与启发
- ⑤ Q&A



L4S-LLM 框架概览

图 1: L4S-LLM 框架总览（论文 Fig.2）

设计目标：将 LLM 蒸馏为一个低延迟的网络决策模块，使其能在 L4S 路由器中实时预测：



模块一：多模态状态编码器（State Encoder）

- 网络状态包括：

$s_t = [\text{queue_delay}, \text{RTT}, \text{loss_rate}, \text{flow_count}, \text{ecn_ratio}, \text{throughput}, \dots]$

- 将这些异构信号通过可学习嵌入层映射为 Token 序列：

$$E(s_t) = \text{Embed}(s_t) \in \mathbb{R}^d$$

- 这样，网络状态 语言 token LLM 编码器（让 LLM 以“语言”方式理解网络动态）
- 优点：
 - 实现“网络信号到语言空间”的转化；
 - 为 LLM 的迁移和蒸馏奠定基础。



图 2: 状态编码示意

模块二：专用决策头（L4S-LLM Head）

- 替代传统“逐 token”生成模式，设计 ** 直接动作预测头部 **：

$$\hat{y}_t = \text{Softmax}(W_o \cdot h_t)$$

输出 3 类动作：

- ① Enqueue（入队）
 - ② Drop（丢包）
 - ③ ECN Mark（标记）
- **关键创新**：LLM 不再生成文本，而是一步输出决策，极大降低延迟。
 - 结合历史隐状态 h_{t-1} 捕捉队列时序特征。

从“语言生成”到“控制决策”的范式转变。



模块三：LoRA 蒸馏与轻量化

- 使用 **Low-Rank Adaptation (LoRA)** 对预训练 LLM 进行蒸馏：

$$W' = W + AB^{\top}, \quad \text{rank}(A, B) \ll d$$

- 只训练 A, B ，冻结原模型权重：
 - 减少训练参数数十倍；
 - 支持边缘设备部署；
 - 保留大模型泛化能力。
- 蒸馏目标：

$$\mathcal{L}_{distill} = \|\hat{y}_{LLM} - y_{teacher}\|^2$$

图 3: LoRA 蒸馏示意



模块四：系统集成与在线决策

- L4S-LLM 嵌入路由器内核：
 - ① 内核采样网络状态；
 - ② 状态编码器 LLM Head；
 - ③ 输出动作 队列更新；
- 决策频率：每个 RTT 周期内数百次；
- 推理延迟：低于 1 ms；
- 兼容 L4S 标准接口（ECN 标记）。

图 4: L4S-LLM 在线部署流程



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述
- ④ 讨论与启发
- ⑤ Q&A



主要结果

- 测试平台：FreeBSD + L4S 模块；
- 对比：传统 L4S vs L4S-LLM；
- 结果：
 - 平均队列延迟下降 35–50%；
 - 带宽利用率提升 10%；
 - 丢包率下降显著；
 - 模型推理时间 < 1 ms。

图 5: 性能比较（论文 Fig.11–15）



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述
- ④ 讨论与启发
- ⑤ Q&A



讨论与启发

- **优势：**首次将 LLM 蒸馏用于实时网络控制任务；
- **通用性：**框架可迁移至拥塞控制、调度、路由优化等；
- **局限：**
 - 仍依赖 GPU 加速；
 - 实际多路并发部署需进一步优化；
- **对课题组的启发：**
 - 可借鉴“LoRA 蒸馏 + 控制头部”思路；
 - 探索 LLM 在系统层实时控制中的落地。



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述
- ④ 讨论与启发
- ⑤ Q&A



Q&A

- 看论文困难，一大堆的专业词汇，每个字都认识，放到一起就不认识了
- 按照上次讨论的框架总结不出来，目前主要靠 AI；自己总结的说是在总结，其实就是复制粘贴论文内容，越总结越多，自己都不想看
- 挺多文章都有很好看的配图，他们是怎么画出来的



WELCOME FEEDBACK!

