

Distilling Large Language Models for Network Active Queue Management

论文汇报

汇报人：巫文杰 指导教师：曹建宇

计算机与信息安全学院

2025 年 11 月 6 日

- 作者：Shiva Raj Pokhrel, et al.
- 发表：arXiv 2025 (预印本)



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述



研究背景与问题动机

- **Active Queue Management (AQM)**: 网络路由器通过主动丢包或 ECN 标记避免拥塞。
- 传统方法 (如 CoDel、PIE、L4S) 依赖固定规则, 难以应对:
 - 异构流量类型 (TCP、UDP、DCTCP 等)
 - 高速 / 低延迟场景 (5G、卫星网)
- 作者提出: **能否让 LLM 参与队列控制决策?**

挑战:

- ① 网络状态是多模态时序数据, 不是自然语言;
- ② LLM 推理延迟高, 不适合实时决策;
- ③ 完整微调代价巨大。



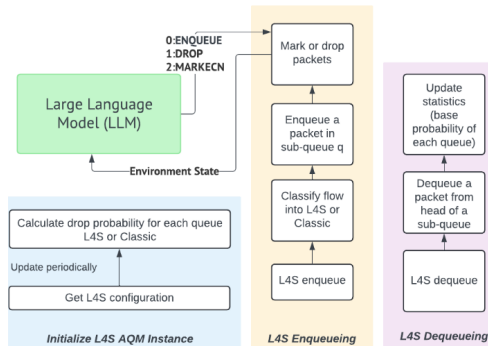


图 1: 功能示意

设计目标： 用 LLM 替代之前基于规则的传统方式，实现更智能的队列管理



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述



L4S-LLM 框架概览

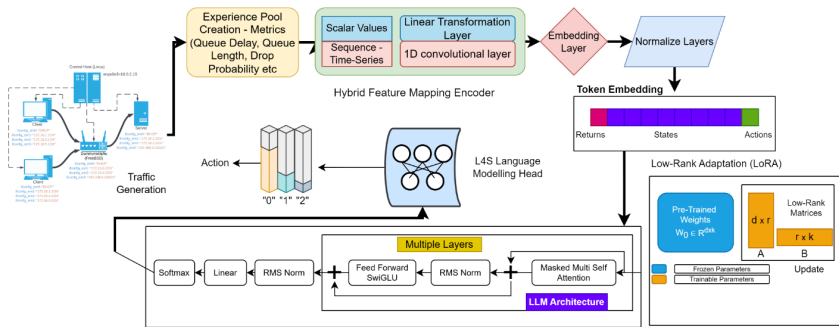


图 2: L4S-LLM 框架总览 (论文 Fig.2)

工程目标: 将 LLM 蒸馏为一个低延迟的网络决策模块, 使其能在 L4S 路由器中实时预测

模块一：多模态状态编码器 (State Encoder)

- 网络状态包括：

$$s_t = [\text{queue_delay}, \text{RTT}, \text{loss_rate}, \text{flow_count}, \text{ecn_ratio}, \text{throughput}, \dots]$$

- 将这些异构信号通过可学习嵌入层映射为 Token 序列：

$$E(s_t) = \text{Embed}(s_t) \in \mathbb{R}^d$$

- 这样，数据实现了从（网络状态）到（语言 token）到（LLM 编码器）的转变（让 LLM 以“语言”方式理解网络动态）
- 优点：
 - 实现“网络信号到语言空间”的转化；
 - 为 LLM 的迁移和蒸馏奠定基础。



模块二：专用决策头 (L4S-LLM Head)

- 替代传统“逐 token”生成模式，设计“直接动作预测头部”：

$$\hat{y}_t = \text{Softmax}(W_o \cdot h_t)$$

输出 3 类动作：

- ① Enqueue (入队)
 - ② Drop (丢包)
 - ③ ECN Mark (标记)
- **关键创新**：LLM 不再生成文本，而是一步输出决策，极大降低延迟。

从“语言生成”到“控制决策”的范式转变。



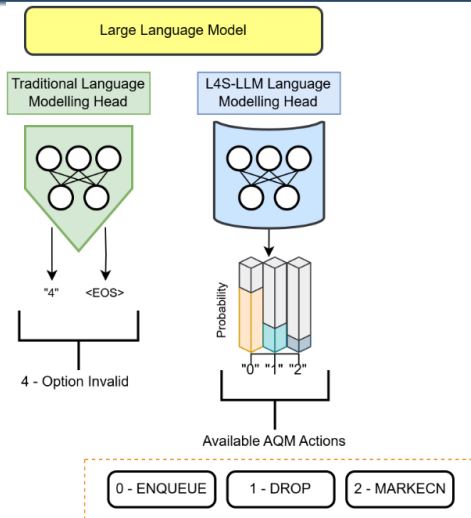


图 3: 专用决策头



模块三：LoRA 蒸馏与轻量化

- 使用 **Low-Rank Adaptation (LoRA)** 对预训练 LLM 进行蒸馏：

$$W' = W + AB^T, \quad r \ll \min(d, k)$$

- 只训练 A, B ，冻结原模型权重：
 - 减少训练参数数十倍；
 - 支持边缘设备部署；
 - 保留大模型泛化能力。




图 4: LoRA 蒸馏示意



目录

- ① 研究背景与问题动机
- ② 研究设计（核心部分）
- ③ 实验与结果简述**



主要结果

- 测试平台：FreeBSD + L4S 模块；
- 对比：传统 L4S vs L4S-LLM；
- 结果：
 - 平均队列延迟下降 35–50%；
 - 带宽利用率提升 10%；



WELCOME FEEDBACK!

