

《Attention Is All You Need》

论文汇报

汇报人：巫文杰 组员：郭子骏、罗豪、何京翰（排名不分先后）

计算机与信息安全学院
2025 年 10 月 11 日

- 作者：Ashish Vaswani et al.
- 发表：NeurIPS 2017
- 来源：Google Brain, Google Research, University of Toronto



① 研究动机与问题定义

② 相关工作

③ 方法 Methodology

④ 实验 Experiments

⑤ 总结 Conclusion



研究动机

- 序列建模任务（如机器翻译）通常基于 RNN 或 CNN。
- 但 RNN 存在“顺序依赖”问题，难以并行，训练慢。
- CNN 可并行但难捕获长距离依赖。
- 因此，论文提出：能否完全依靠 **Attention** 替代循环与卷积？

讲述建议：从机器翻译的痛点入手，引出“Attention-only”这一大胆想法。



问题定义

- 任务：序列到序列 (Seq2Seq) 建模。
- 目标：设计一个**更快、更并行、捕捉长依赖**的新架构。
- 关键问题：
 - 如何在不使用 RNN/CNN 的前提下建模序列关系？
 - 如何保持信息的顺序感？



① 研究动机与问题定义

② 相关工作

③ 方法 Methodology

④ 实验 Experiments

⑤ 总结 Conclusion



相关工作简述

- RNN: LSTM、GRU ——解决梯度消失，但串行计算限制并行。
- CNN: ConvS2S、ByteNet ——并行性好，但捕获远程依赖效率低。
- Self-Attention ——在阅读理解、摘要生成中已有应用，但未完全替代 RNN。

核心突破：Transformer 是首个完全依赖自注意力（Self-Attention）的 Seq2Seq 模型。



① 研究动机与问题定义

② 相关工作


③ 方法 Methodology

④ 实验 Experiments

⑤ 总结 Conclusion



模型整体框架



- 编码器-解码器结构，各包含 6 层堆叠。
- 核心模块：多头自注意力（Multi-Head Self-Attention）。
- 通过残差连接 + LayerNorm 稳定训练。

讲述建议：用图带讲，强调“并行性 + 层次结构”。



Scaled Dot-Product Attention

- 输入：Query、Key、Value 三组向量。
- 计算：


$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- 实质：通过相关性加权求和。
- 优点：矩阵乘法实现，支持并行，计算高效。




Multi-Head Attention

Scaled Dot-Product Attention



Multi-Head Attention



- 多头注意力允许模型关注不同子空间的信息。
- 每个“头”独立学习不同的依赖关系。
- 八个头并行后再拼接，得到最终输出。

直观解释：每个头像一个“专家”，关注句子中的不同语义关系。



位置编码 Positional Encoding

- 因为模型不含 RNN/CNN，所以需显式加入位置信息。
- 采用**正弦-余弦函数**编码：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

- 能让模型学会按相对位置进行注意。



① 研究动机与问题定义

② 相关工作

③ 方法 Methodology

④ 实验 Experiments

⑤ 总结 Conclusion



实验设置

- 数据集：WMT 2014 英-德 (4.5M 句对)，英-法 (36M 句对)。
- 硬件：8 × NVIDIA P100 GPU。
- 优化器：Adam，学习率调度带 Warm-up (4000 步)。
- 正则化：Dropout=0.1，Label Smoothing=0.1。



机器翻译结果


Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

- EN-DE: BLEU = 28.4 (+2.0 优于 SOTA)
- EN-FR: BLEU = 41.8 (单模型新纪录)
- 训练仅需 3.5 天，比 GNMT 节省 75% 计算量。

讲述建议：强调“性能 + 效率”双突破。



可视化与可解释性



发现：不同注意力头能自动学习语法结构、共指关系等语义模式。

① 研究动机与问题定义

② 相关工作

③ 方法 Methodology

④ 实验 Experiments

⑤ 总结 Conclusion



总结与展望

- 提出第一个完全基于注意力的序列转换模型 Transformer。
- 实现更强性能、更高并行度、更低训练成本。
- 后续方向：
 - 将注意力机制扩展到图像、语音、多模态任务。
 - 优化局部注意力处理长序列。

一句话总结: “*Attention replaces recurrence and convolution — and works even better.*”



致谢

WELLCOME FEEDBACK!

